

CUANTIFICACIÓN DE INCERTIDUMBRE

Predicción Conforme

Conformal Prediction

Intervalos con garantía de cobertura, sin asumir distribución

Dr. Alejandro E. Rodríguez-Sánchez
Universidad Panamericana, Campus Guadalajara
X: @_arods



¿Qué es Conformal Prediction?

Un **framework matemático** que convierte cualquier modelo de Machine Learning en uno que produce predicciones con **garantías estadísticas de cobertura**.

En lugar de una predicción puntual — “*el precio será \$250*” — entrega un **intervalo**, con la garantía de que el valor real caerá dentro con la probabilidad que tú elijas (90%, 95%).

Cuantil ($\hat{q}$): el umbral que deja por debajo una fracción $(1-\alpha)$ de los scores de calibración. Si el 90% de los errores fueron $\leq \hat{q}$, ese $\hat{q}$ define el ancho del intervalo: $[\hat{y} - \hat{q}, \hat{y} + \hat{q}]$.

LA GRAN VENTAJA

Agnóstico al modelo

Funciona con Random Forest, XGBoost, redes neuronales — cualquier estimador.

Libre de distribución

No asume normalidad ni forma alguna de los datos.

Garantía formal

La cobertura se cumple en sentido matemático, no aproximado.

El score mide el error punto a punto; el cuantil resume todos esos errores en un solo número que fija el tamaño del intervalo.

Los pasos conceptuales

1

Dividir los datos

Tres conjuntos:
entrenamiento,
calibración y test.

2

Entrenar el modelo

Se ajusta normalmente
sobre el conjunto de
entrenamiento.

3

Scores de no-conformidad

En calibración se mide el
error de cada punto: el
residuo absoluto.

4

Calcular el cuantil

Se toma el cuantil $(1-\alpha)$
de esos scores: el umbral
 $\hat{q}$.

5

Construir el intervalo

Para datos nuevos: $[\hat{y}-\hat{q},$
 $\hat{y}+\hat{q}]$.

Score (de no-conformidad): mide cuánto se equivoca el modelo en cada punto. En regresión es el residuo absoluto $s = |y - \hat{y}|$. Cuanto mayor, más "raro" o no-conforme es ese dato respecto a la predicción.

Cuantil de calibración e intervalo

4 Calcular el cuantil

Eliges un nivel de error α (p. ej. $\alpha = 0.1$ para 90% de cobertura) y tomas el cuantil $(1-\alpha)$ ajustado de los scores de calibración:

$$\hat{q} = \text{Quantile}\left(\frac{\lfloor (n+1)(1-\alpha) \rfloor}{n}\right) \text{ de los scores}$$

5 Construir la predicción en test

Para regresión, el intervalo de predicción es simplemente:

$$[\hat{y} - \hat{q}, \hat{y} + \hat{q}]$$

Garantía teórica


$$P(Y_{\text{test}} \in C(X_{\text{test}})) \geq 1 - \alpha$$

La probabilidad de que el valor real caiga dentro del intervalo es **al menos $1-\alpha$** .

Se cumple sin importar el modelo ni la distribución de los datos.

El intervalo básico tiene ancho constante

Split Conformal — ancho constante



El split conformal usa un **único cuantil $\hat{q}$** y lo aplica igual en todo el rango: el ancho $2\hat{q}$ **no cambia con x** .

Problema: si el ruido crece en ciertas regiones, el intervalo queda **demasiado estrecho en los extremos** y demasiado ancho en el centro.

*La cobertura global se cumple, pero la **cobertura local** queda mal repartida.*

CQR – Conformalized Quantile Regression


La idea: no modelar la media, sino los **cuantiles** directamente.

Se entrenan modelos para el cuantil bajo (p. ej. 5%) y el alto (95%). Esos cuantiles **ya capturan la forma del ruido**: se separan donde hay más dispersión y se juntan donde hay menos.

Conformal entonces aplica una **pequeña corrección de calibración E** a esa banda para garantizar el $1-\alpha$ exacto:


$$[\hat{q}_{lo}(x) - E, \hat{q}_{hi}(x) + E]$$

CQR modela cuantiles, no la media




Ancho fijo vs. ancho adaptativo

Split Conformal — ancho constante



CQR — el ancho sigue al ruido



Cobertura repartida de forma pareja a lo largo de todo el dominio: el intervalo se abre justo donde el modelo es menos certero.

Dos variantes, una misma garantía

Split Conformal

Modela la media $\hat{y}$
Ancho constante $2\hat{q}$
Simple y rápido de calibrar

Ideal cuando el ruido es **homogéneo** en todo el dominio.

CQR (adaptativo)

Modela los cuantiles $\hat{y}(x)$
Ancho variable según x
Captura heterocedasticidad

Ideal cuando la incertidumbre **cambia con la región** del espacio de entrada.

UN FRAMEWORK POTENTE PARA CUANTIFICAR INCERTIDUMBRE SIN ASUMIR DISTRIBUCIÓN

Incertidumbre cuantificable y rigurosa

La Predicción Conforme transforma cualquier modelo que solo da estimaciones puntuales en uno que ofrece intervalos de confianza con garantías estadísticas exactas (cobertura del $1-\alpha$), sin asumir distribuciones específicas en los datos.

Adaptabilidad con CQR

Mientras que el método estándar (Split Conformal) genera intervalos de ancho fijo que pueden ignorar la variabilidad local, Conformalized Quantile Regression (CQR) se adapta a la heterocedasticidad, ensanchando los intervalos donde el modelo tiene más error y estrechándolos donde es más seguro.

Implementación práctica y universal

Es una capa adicional, ligera y computacionalmente eficiente que se puede colocar encima de cualquier algoritmo de Machine Learning moderno (Random Forest, XGBoost, Redes Neuronales) utilizando simplemente un conjunto de datos de calibración independiente.